

Індивідуальне завдання: класифікація.

Встановіть значення змінної `variant`: сума номера групи помноженого на 25 і порядкового номеру студента в списку групи (групі ПМОм-11 відповідає номер 0, групі ПМІм-11 відповідає номер 1, групі ПМІм-12 відповідає номер 2, групі ПМІм-13 відповідає номер 3). Далі встановіть `set.seed(variant)` та згенеруйте значення змінної `redundant` як заокруглене до цілого (для заокруглення можна використати функції `floor` або `round`) випадкове число з рівномірного на інтервалі (номер групи + 5, 25 – номер групи) розподілу (функція `runif`). Також згенеруйте значення змінної `year` як заокруглене до цілого випадкове число з рівномірного на інтервалі (2006, 2008) розподілу.

1. Використовуючи дані `Weekly`, встановивши `seed`, що дорівнює значенню змінної `variant`, побудуйте модель логістичної регресії для передбачення `Direction` з використанням навчальних даних з 1990 по `year` pp., на основі єдиного предиктора `Lag2`. Обчисліть матрицю помилок та загальну частку правильних прогнозів на тестових даних (тобто даних за `year`-2010 роки). За аналогічних умов використайте для передбачення `Direction` лінійний дискримінантний аналіз, квадратичний дискримінантний аналіз та метод К-найближчих сусідів з $K = 1$. Порівняйте використані методи. За якого K точність методу К-найближчих сусідів буде найбільшою?

2. Модифікуйте дані `Auto` наступним чином: встановивши `seed`, що дорівнює значенню змінної `variant`, видаліть `redundant %` спостережень з допомогою функції `sample`. Створіть двійкову змінну `mpg01`, яка містить 1, якщо `mpg` містить значення більше за середнє, і 0, якщо `mpg` містить значення менше за середнє. Розбийте дані на навчальний та тестовий набори. При розбитті набору даних **обов'язково!!!** встановити `seed`, що дорівнює значенню змінної `variant`, та використати функцію `sample`. Обсяг тестової вибірки виберіть $2 * \text{redundant \%}$ від загального обсягу даних. Застосуйте лінійний дискримінантний аналіз, квадратичний дискримінантний аналіз, логістичну регресію та метод К-найближчих сусідів з різними значеннями для K на навчальних даних, щоб передбачити `mpg01` на основі змінних `weight`, `displacement` та `horsepower`. Порівняйте тестові помилка використаних моделей. За якого K точність методу К-найближчих сусідів буде найбільшою та якою буде точність цього методу?